Comparação de Classificadores para a Base Adult

Matheus Costa Monteiro – 17756099
PCS5024 – Aprendizado Estatístico
28 de abril de 2026

Resumo

Este trabalho apresenta uma comparação entre três classificadores para a base *Adult*: k-nearest neighbors (kNN), *Linear Support Vector Machine* (SVM) e Regressão Logística. A implementação foi organizada para preservar comparabilidade metodológica: os três modelos usam os mesmos dados preparados, o mesmo subconjunto de atributos, a mesma divisão estratificada entre **treino** e **validação**, o mesmo protocolo de validação cruzada (*cross-validation*) em cinco partições e a mesma avaliação final no conjunto de **teste**. O relatório conecta conceitos centrais da disciplina — preparação de dados, classificação supervisionada, seleção de hiperparâmetros, regularização e métricas de avaliação — com decisões concretas de implementação. Os resultados mostram que a Regressão Logística obteve a maior *accuracy* no teste, enquanto o kNN apresentou os melhores valores de *balanced accuracy*, *recall*, F1 e ROC AUC para a classe positiva (*income>50k*). A SVM linear apresentou comportamento mais conservador, com maior precisão e maior especificidade. O código-fonte e os artefatos de execução estão disponíveis em github.com/costadev00/classifier-adults-dataset.

1 Introdução

O objetivo do trabalho foi construir um classificador kNN para prever a variável `income` equivalente ao ganho anual da amostra(pessoa), e compará-lo com mais dois classificadores distintos, usando as métricas *accuracy*, *precision*, *recall* e F1. Neste trabalho, a variável-alvo foi binarizada **definindo-se a classe negativa como `<=50K` e a classe positiva como `>50K`**. Assim, as métricas de precisão, recall e F1 referem-se à identificação da classe positiva `>50K`.

As métricas utilizadas têm o seguinte papel. A *accuracy* mede a proporção total de previsões corretas. A *precision* da classe positiva mede, entre os exemplos previstos como `>50K`, quantos realmente pertencem a essa classe. O *recall* da classe positiva mede, entre os exemplos realmente `>50K`, quantos foram recuperados pelo modelo. Por fim, a medida F1 resume o compromisso entre *precision* e *recall*, sendo especialmente útil quando se deseja avaliar simultaneamente a qualidade e a cobertura das previsões da classe positiva.

Para que a comparação entre os classificadores fosse válida, a implementação foi conduzida como um único protocolo experimental, e não como três notebooks independentes com decisões de preparação diferentes. Isso significa que os modelos foram comparados com a mesma base preparada, o mesmo conjunto de atributos, a mesma divisão entre conjunto de treino e conjunto de teste, o mesmo protocolo de validação cruzada para seleção de hiperparâmetros e as mesmas métricas finais de avaliação.

O repositório evoluiu em etapas curtas e cumulativas, começando pelo download e diagnóstico dos dados, passando pela preparação consolidada da base e culminando nos três modelos finais. A Tabela 1 resume os marcos principais observados no histórico de commits.

Tabela 1: Linha do tempo resumida da implementação.

Commit	Papel na implementação
4a84aed	Download dos arquivos originais e início da preparação.
38ef825	Diagnóstico da base e inspeção de qualidade dos dados.
71f23f0	Geração de train_prepared.csv, test_prepared.csv e manifesto de preparação.
8a558d9	Primeiro baseline completo com kNN.
a482c88	Refinamento metodológico do notebook de kNN e ampliação das métricas.
d9e7517	Implementação da SVM linear com o mesmo protocolo do kNN.
9f25417	Implementação final da Regressão Logística e consolidação da comparação.
0866a4d	Documentação conceitual da Regressão Logística no notebook.

Seguindo a ordem conceitual trabalhada na disciplina, primeiro foi necessário entender os dados e controlar a preparação da base; em seguida, selecionar hiperparâmetros por validação cruzada no conjunto de desenvolvimento; por fim, avaliar os classificadores no conjunto de teste sob o mesmo protocolo experimental. Essa organização permitiu transformar conceitos centrais da disciplina, como preparação de atributos, validação cruzada, escolha de hiperparâmetros e comparação de classificadores, em uma implementação consistente e reproduzível.

2 Data Prep

A etapa de preparação foi consolidada em `notebooks/02_data_preparation.ipynb`. Os dados utilizados no trabalho tiveram como referência as fontes indicadas no enunciado da atividade: a competição no Kaggle e o repositório UCI da base *Adult* (UCI Adult Dataset). A partir desses arquivos de origem, o objetivo dessa fase foi construir uma interface estável para os classificadores seguintes, composta por `train_prepared.csv`, `test_prepared.csv` e arquivos auxiliares de documentação. Essa separação foi decisiva porque evitou repetir decisões de limpeza e evitar re-engenharia em cada notebook, reduzindo inconsistências e risco de vazamento de dados, como discutido nas primeiras aulas da disciplina.

Um ponto importante da preparação foi o tratamento dos atributos categóricos com informação ausente. Na base original, os valores faltantes não apareciam como ausência formal, mas como o texto "?" em `workclass`, `occupation` e `native.country`. Esses casos foram reinterpretados como faltantes reais e, em vez de serem preenchidos pela categoria mais frequente, passaram a ser representados por uma categoria explícita, `__MISSING__`. Essa escolha evita atribuir artificialmente uma ocupação, classe de trabalho ou país a observações cujo valor é desconhecido, o que poderia distorcer a distribuição original da base. Além disso, também foram criados indicadores específicos para registrar se cada um desses atributos estava ausente originalmente. No conjunto de treino, foram identificados 1.836 faltantes em `workclass`, 1.843 em `occupation` e 582 em `native.country`; no conjunto de teste, esses números foram 963, 966 e 274, respectivamente. Do ponto de vista da modelagem, essa estratégia faz sentido porque a ausência de informação pode carregar sinal próprio: não informar `occupation` ou `workclass`, por exemplo, pode estar associado a um perfil diferente de renda. Assim, em vez de mascarar esse padrão, a preparação permitiu que os classificadores tratassem o valor ausente como uma condição observável do problema.

As principais decisões de preparação foram as seguintes:

- substituição do símbolo "?" por ausência de informação nas variáveis `workclass`, `occupation` e `native.country`;
- criação de marcadores explícitos de ausência para essas três variáveis categóricas;
- remoção apenas de repetições exatas no conjunto de treino quando atributos e rótulo coincidiam;
- preservação dos casos em que os atributos se repetiam, mas o rótulo diferia, mantendo esses registros apenas sinalizados para diagnóstico;
- transformação das variáveis mais assimétricas ligadas a peso amostral e capital, de modo a reduzir a concentração em valores extremos sem eliminar observações;
- criação de indicadores simples para presença de ganho de capital, perda de capital e jornadas semanais mais altas;
- agrupamento dos níveis de escolaridade em categorias mais estáveis, preservando a distinção entre

níveis avançados relevantes;
- criação de faixas etárias para representar idade de forma mais agregada;
- criação de um atributo combinado entre estado civil e papel familiar.

Essas escolhas buscaram reduzir ruído e tornar a base mais estável para modelagem, sem descaracterizar o problema original.

A célula abaixo foi a âncora da comparação justa entre os três modelos. Ela fixa o mesmo subconjunto compacto de variáveis para kNN, SVM e Regressão Logística. Em outras palavras, a comparação passou a ser entre classificadores, e não entre versões diferentes do problema.

A ideia central foi reduzir ruído sem descaracterizar a base, mantendo o máximo possível de informação útil para a etapa de classificação.

A célula abaixo foi a âncora da comparação justa entre os três modelos. Ela fixa o mesmo subconjunto compacto de variáveis para kNN, SVM e Regressão Logística. Em outras palavras, a comparação passou a ser entre classificadores, e não entre versões diferentes do problema.

Listing 1: Seleção comum de atributos para os três classificadores.

```
NUMERIC_FEATURES = [
    "age", "education.num", "hours.per.week",
    "log1p_fnlwgt", "log1p_capital_gain", "log1p_capital_loss"
]

CATEGORICAL_FEATURES = [
    "workclass", "marital.status", "occupation",
    "relationship", "race", "sex", "native.country"
]

SELECTED_FEATURE_COLUMNS = NUMERIC_FEATURES + CATEGORICAL_FEATURES
X_train_full = train_prepared[SELECTED_FEATURE_COLUMNS].copy()
y_binary = (train_prepared[TARGET_COL] == POSITIVE_LABEL).astype(int)
```

A base preparada ficou com 32.536 exemplos rotulados para treino e 16.280 exemplos para teste. É importante notar que a base fornecida pelo trabalho já vinha originalmente separada entre treino e teste, e, por uma questão de lisura metodológica, essa divisão foi preservada ao longo de toda a implementação. Em outras palavras, não houve redistribuição entre esses dois conjuntos; todas as decisões de preparação respeitaram a separação original proposta no enunciado. Dentro do conjunto de treino, a distribuição da variável-alvo também foi preservada no particionamento estratificado entre treino e conjunto de teste: aproximadamente 75,9% na classe `<=50K` e 24,1% na classe `>50K`. **Essa assimetria explica por que a análise dos classificadores não se apoiou apenas em acurácia (*accuracy*),** sendo necessário observar também *precision*, *recall* e F1 para a classe positiva.

3 kNN

O kNN foi o primeiro modelo completo do projeto e serviu como base comparativa. Sua conexão com a disciplina é direta: trata-se de um classificador supervisionado não paramétrico, cuja decisão depende da vizinhança local no espaço de atributos. Como a disciplina enfatiza o papel da representação dos dados, esse modelo tornou explícito por que escala, codificação e dimensionalidade importam.

O notebook `03_knn_classifier.ipynb` adotou um *Pipeline* com imputação, codificação *one-hot-encoding* e *RobustScaler*, seguido de um `GridSearchCV` com `StratifiedKFold`. O melhor modelo selecionado utilizou $k = 61$, pesos uniformes e distância Manhattan. Esse resultado é coerente com o compromisso viés-variância discutido em aula: um k relativamente grande suaviza a fronteira e reduz sensibilidade a ruído.

No *holdout*(teste), o kNN obteve uma *acurácia* de **0,84819**, *balanced accuracy* de 0,77354, *precisão* de 0,70803, *recall* de 0,62946, F1 de 0,66644 e ROC AUC de 0,90215. O ponto principal é que o kNN foi o modelo mais forte nas métricas mais sensíveis à classe positiva. Em um cenário desbalanceado, isso significa que ele encontrou mais exemplos `>50K` sem degradar excessivamente o restante da avaliação.

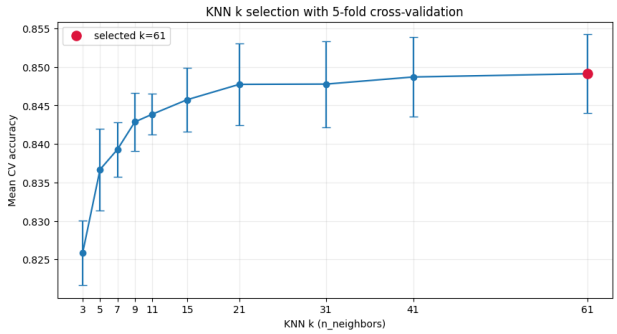

Figura 1: kNN em validação cruzada

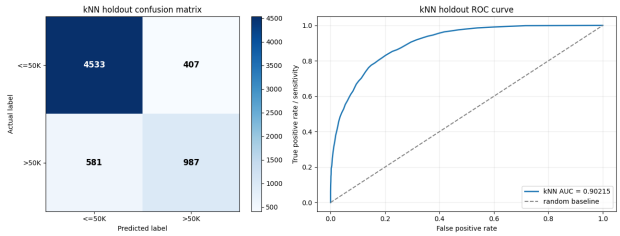

Figura 2: Resultados do kNN

4 SVM

A SVM linear foi implementada em `04_svm_classifier.ipynb` com o mesmo protocolo experimental do kNN. A conexão com a teoria é igualmente clara: a SVM busca um hiperplano separador com margem máxima, regulado pelo hiperparâmetro C. O modelo escolhido foi uma `LinearSVC` com $C = 0{,}03$, também selecionada por validação cruzada em cinco partições.

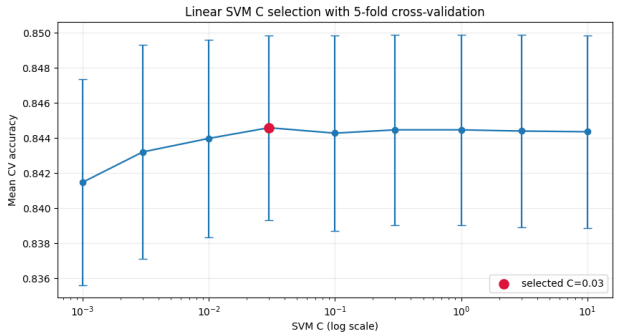

Figura 3: SVM em validação cruzada

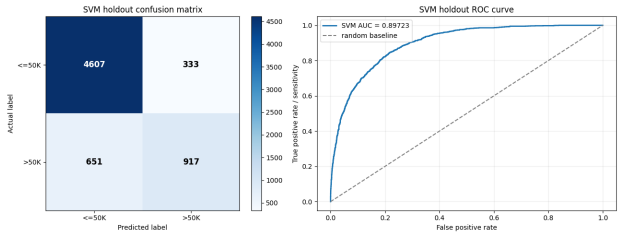

Figura 4: Resultados da SVM

O aspecto mais importante aqui não foi apenas o valor final de C, mas o fato de que a SVM recebeu exatamente o mesmo problema já preparado para o kNN. Assim, a diferença observada nas métricas pode ser interpretada como diferença de técnica: vizinhança local no kNN versus fronteira linear global regularizada na SVM.

No *holdout*, a SVM linear obteve *accuracy* de 0,84880, *precision* positiva de 0,73360, *recall* de 0,58482, *specificity* de 0,93259 e F1 de 0,65082. O modelo foi mais conservador: reduziu falsos positivos e aumentou a especificidade, mas ao custo de perder mais positivos verdadeiros. Isso se alinha ao comportamento esperado de um classificador linear regularizado quando comparado a um método baseado em vizinhança.

5 Logistic Regression

A Regressão Logística fechou o trio de modelos em `05_logistic_regression_classifier.ipynb`. Ela foi escolhida por estar fortemente alinhada ao conteúdo da disciplina: é um classificador discriminativo probabilístico que modela diretamente $P(Y = 1 \mid X)$, com fronteira linear no espaço transformado. Além disso, o notebook documenta a passagem entre teoria e implementação: os coeficientes β_i continuam existindo, mas são estimados numericamente pelo *solver* do `scikit-learn`, em vez de serem calculados manualmente.

Na prática, a implementação reutilizou o mesmo *Pipeline*, o mesmo conjunto de atributos e o mesmo *split* estratificado. O hiperparâmetro central foi novamente C, agora interpretado como controle inverso da força de regularização. O melhor modelo selecionado utilizou $C = 0{,}3$.

No *holdout*, a Regressão Logística obteve *accuracy* de 0,85049, *precision* positiva de 0,73297, *recall* de 0,59694, *specificity* de 0,93097 e F1 de 0,65800. O resultado mostra um equilíbrio interessante: a

Figura 5: Regressão logística em validação cruzada

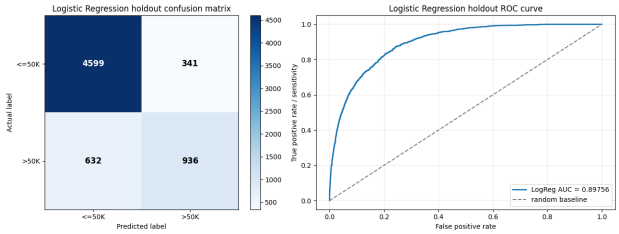

Figura 6: Resultados da Regressão Logística

Regressão Logística superou ligeiramente os demais em *accuracy*, manteve *precision* alta e, ao mesmo tempo, recuperou mais positivos do que a SVM. Em termos de narrativa do trabalho, ela funcionou como um modelo linear probabilístico equilibrado e interpretável.

6 Resultados

A Tabela 2 resume a comparação final no *holdout*. Embora o enunciado exija *accuracy*, *precision*, *recall* e F1, incluímos também *balanced accuracy*, *specificity* e ROC AUC porque a base é desbalanceada e essas métricas ajudam a explicar por que classificadores com *accuracy* muito próxima podem ter comportamentos bem diferentes.

Tabela 2: Comparação final entre os três classificadores no *holdout*.

Modelo	Accuracy	Bal. Acc.	Prec.+	Recall+	F1+	Spec.	ROC AUC
kNN	0.84819	0.77354	0.70803	0.62946	0.66644	0.91761	0.90215
Linear SVM	0.84880	0.75871	0.73360	0.58482	0.65082	0.93259	0.89723
Regressão Logística	0.85049	0.76396	0.73297	0.59694	0.65800	0.93097	0.89756

A leitura dos resultados não é unidimensional. A Regressão Logística apresentou a maior acurácia geral. O kNN foi o mais forte quando o foco passou a ser a classe positiva, com os maiores valores de *balanced accuracy*, *recall*, F1 e ROC AUC. A SVM linear apresentou a maior *precision* positiva e a maior especificidade, confirmando um comportamento mais conservador. Portanto, a conclusão correta não é que existe um vencedor absoluto, mas que cada técnica enfatiza um tipo diferente de erro.

7 Conclusões e próximos passos

O principal resultado do projeto foi metodológico: os três modelos foram comparados sob exatamente as mesmas condições de dados, preparação e avaliação. Essa consistência permitiu conectar diretamente os conceitos vistos na disciplina com a execução do trabalho: preparação de atributos, separação entre treino e teste(*holdout*), validação cruzada para seleção de hiperparâmetros, regularização e interpretação das métricas de classificação.

Em termos de desempenho, a Regressão Logística apresentou a maior acurácia local, o kNN foi o modelo mais forte para a classe positiva e a SVM linear mostrou o perfil mais conservador. Essa diversidade de resultados é, em si, uma evidência de entendimento do problema: escolher um classificador depende do tipo de erro que se quer priorizar, e não apenas de uma única métrica agregada.

Como próximos passos, uma continuação natural seria estudar métodos baseados em árvores e *boosting*, que aparecem adiante no curso e costumam ser fortes em dados tabulares. No contexto desta atividade, porém, o objetivo central já foi atingido: construir, comparar e interpretar três classificadores distintos de forma reprodutível e alinhada à teoria da disciplina.

Referências

[1] BECKER, B.; KOHAVI, R. *Adult*. UCI Machine Learning Repository. Disponível em: `https://archive.ics.uci.edu/dataset/2/adult`. Acesso em: 28 abr. 2026.

[2] PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Documentação disponível em: `https://scikit-learn.org/stable/`. Acesso em: 28 abr. 2026.

[3] COZMAN, F. G. *Aula 1 – Statistical Learning Basics*. PCS5024 – Aprendizado Estatístico, Escola Politécnica da USP, 2026.

[4] COZMAN, F. G. *Aula 2 – Evaluation of Classifiers*. PCS5024 – Aprendizado Estatístico, Escola Politécnica da USP, 2026.

[5] COZMAN, F. G. *Aula 4 – Logistic Regression, LDA and QDA*. PCS5024 – Aprendizado Estatístico, Escola Politécnica da USP, 2026.

[6] COZMAN, F. G. *Aula 5 – Support Vector Machines*. PCS5024 – Aprendizado Estatístico, Escola Politécnica da USP, 2026.

[7] MONTEIRO, M. C. *classifier-adults-dataset*. Repositório GitHub. Disponível em: `https://github.com/costadev00/classifier-adults-dataset`. Acesso em: 28 abr. 2026.